


PORTABLE SYSTEM TO DETECT DRIVER DROWSINESS WITH BODY SENSORS

PAUL PASLER - paul.pasler@student.reutlingen-university.DE



1 Motivation

- Der flächendeckende Einsatz von Fahrerassistenzsystemen könnte die Zahl schwerer Unfälle um bis zu 28% verringern [2]



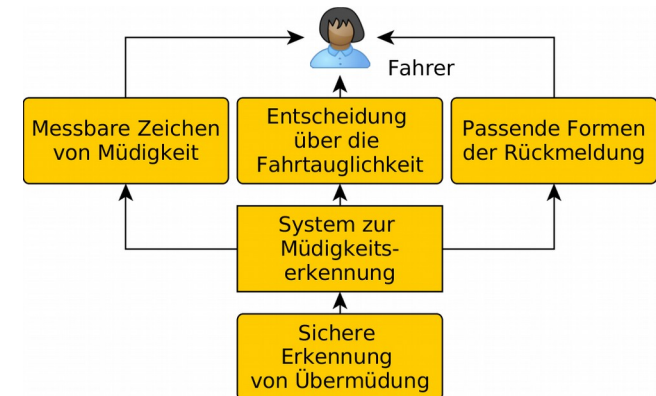
- In Deutschland wurden 2015 rund 2,5 Mio. Unfälle polizeilich aufgenommen, die Zahl der Verkehrstoten liegt bei 3.450 [4]
- Jeder 5. Unfall lässt sich auf Müdigkeit zurückführen [5]



1 Problemstellung / Ziel

Für ein System zur Müdigkeitserkennung müssen

- messbare Zeichen von Müdigkeit ermittelt werden
- eine Entscheidung getroffen werden, ob der Fahrer noch in der Lage ist sein Fahrzeug zu führen
- der Fahrer auf seine aktuelle Fahrtauglichkeit hingewiesen werden



Ziel ist es die Zahl schwerer Unfälle zu verringern, indem der Fahrer rechtzeitig vor drohender Müdigkeit gewarnt wird.

Erkennung von Müdigkeit

- im Fahrzeugumfeld
- mit Körpersensoren (EEG)
- mit leicht portierbarer Hardware
- und verteilter Software-Architektur

2 Stand der Technik

Vorgehensweisen zur Müdigkeitserkennung durch Analyse

- des Fahrverhaltens
- von optischen Parametern (Computer Vision, CV)
- von Körpersignalen

Körpersensoren

- Analyse nur mit EKG / EOG keine eindeutigen Ergebnisse [10][11]
- Kombinationen EKG / EEG und EOG / EEG liefern gute Ergebnisse, im Vergleich reicht jedoch auch nur das EEG aus [13]
- Verschiedene Arbeiten nur mit dem EEG
 - Subasi et al. [14] Unterscheidung von „wach“, „schläfrig“ und „schlafen“, Künstliches Neuronale Netz (KNN), Erkennungsrate 93%
 - Vuckovic et al. [15] Suche nach bestem Algorithmus für den Aufbau eines KNN, Erkennungsrate 90%
 - Weitere Arbeiten mit EEG: Huang et al. [16] 90%, Lin et al [17] 88%

2 Analyse

- Fahrverhaltens- und CV-Ansätze grundsätzlich geeignet, werden jedoch nur zum Labeln der EEG Sequenzen herangezogen
- Das EEG eignet sich sehr gut für die Erkennung von Müdigkeit
- Entweder medizinisches EEG oder Eigenentwicklungen
- Keine Tests in echten Fahrsituationen
- KNN wird häufig verwendet (aber auch LDA, HMM, SVM)

3 Anforderungen

Must

- Präzision und Korrektheit (> 90% Erkennungsrate)
- Performance (nahezu Echtzeit)
- Portabilität (Simulator / echtes Fahrzeug)
- Robust gegen Fehler / Fehleingaben sein
- Einfache Handhabung und möglichst hoher Tragekomfort

Should

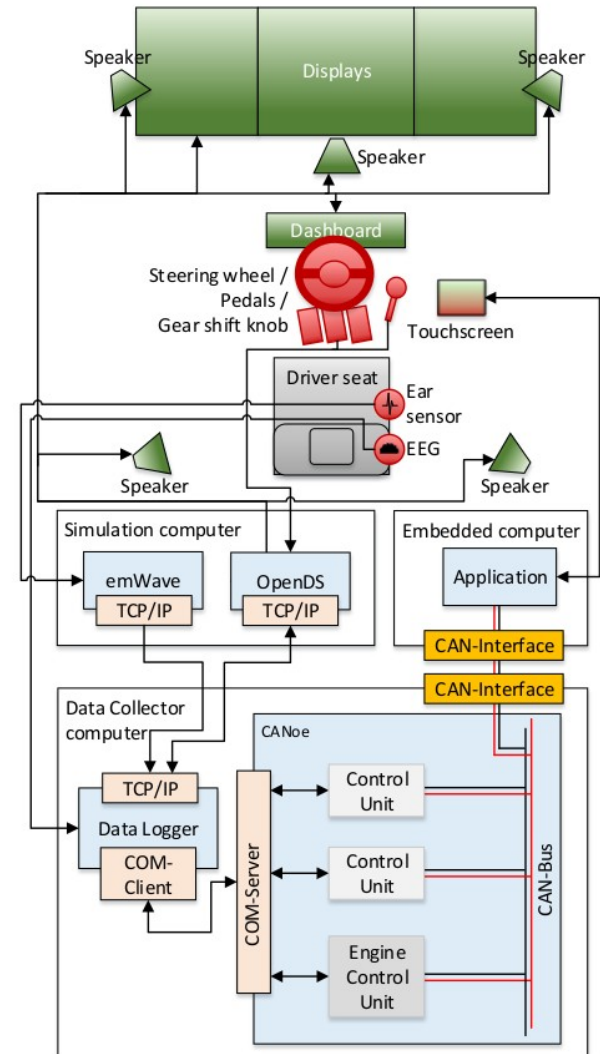
- Flexibilität
 - Verschiedene Betriebssysteme und Gerätetypen (Ressourcenverbrauch Smartphone)
 - Verteilte Anwendung
- Eindeutige Kommunikation mit dem Fahrer

Qualität

- Dokumentation
- Testabdeckung

4 Infrastruktur

- Anwendung muss in der **Fahrsimulator** Umgebung laufen
- Anwendung wird in Python 2.7 geschrieben
 - Leicht zu lernen und zu verstehen
 - Bibliotheken für wissenschaftliche Berechnungen
 - MachineLearning Bibliotheken
 - Portierbar auf Win / Mac / Linux, Tablet / Smartphone
 - Ausreichende Performance



4 Testdatenbeschaffung / Experiment

Ziel ist es, den Testfahrer möglichst müde zu machen, sodass er deutliche Anzeichen für Müdigkeit zeigt

Dafür werden folgende Parameter gesetzt


- Experiment findet zwischen 14:00 und 16:00 statt [24]
- Schlafmenge vor dem Experiment < 6h [23]
- Simulierte Nachtfahrt (Dunkel)
- Eintönige Geradeausstrecke ohne Abwechslung
- Keine anderen Verkehrsteilnehmer



Szenario im Fahrsimulator

Erhobene Daten

- EEG Rohdaten
- Video (Fahrer / Simulation)
- Fahrzeugdaten (Geschwindigkeit)
- Besondere Ereignis (Abkommen von der Spur)



Aufbau des Experiments

5 Systemübersicht

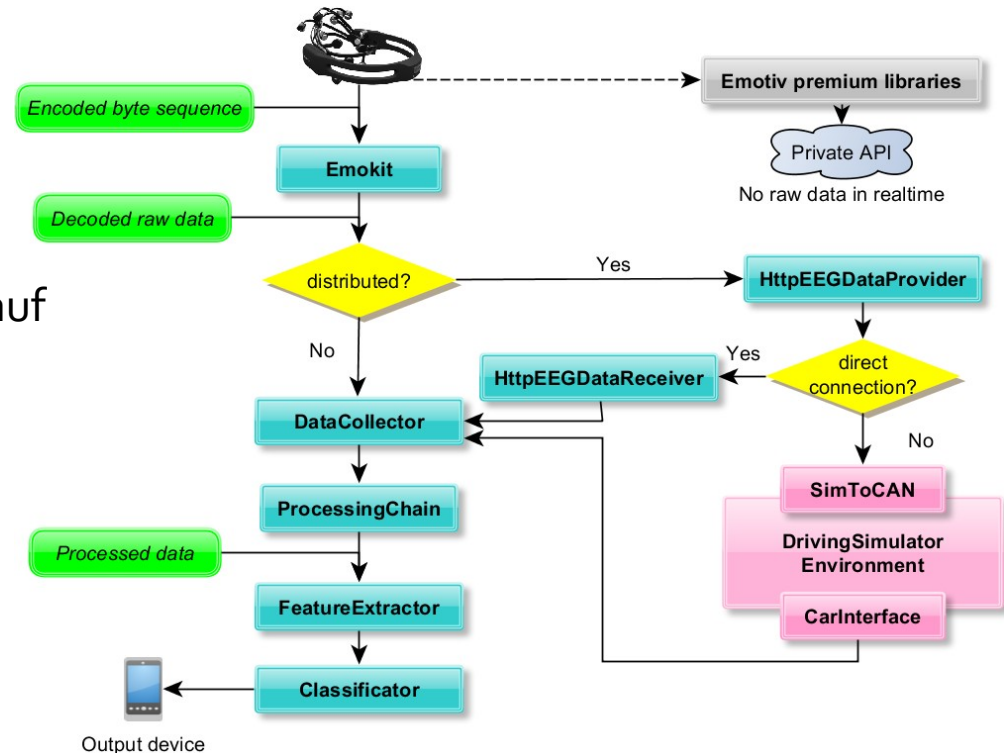
Rohdaten aus Lib „Emokit“

Die Rohdaten können

- direkt (läuft auf einem System)
 - via http (Holen und Verarbeitung auf verschiedenen Systemen)
- übertragen werden

Via http können die Daten

- von einem http-Client
- mit CAN über den Simulator zur Verarbeitung geleitet werden



Außer „Emokit“, sind alle blauen Klassen Eigenentwicklungen. Am Fahrsimulator wurde das EEG-Daten-Handling implementiert.

5 Systemintegration

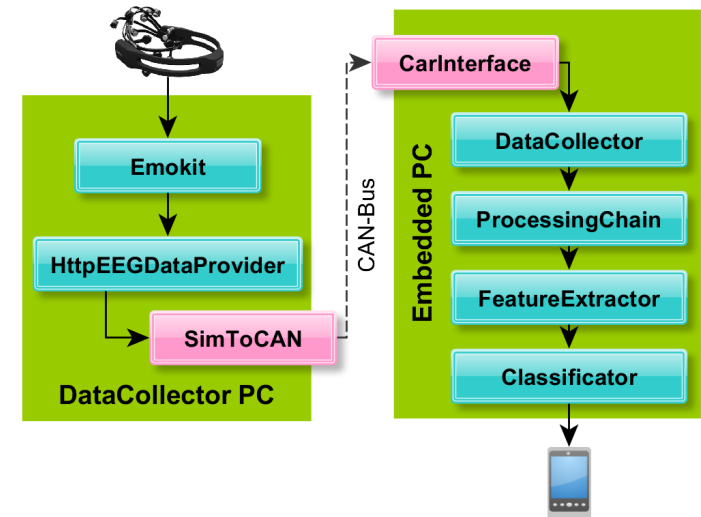
DataCollector PC

- via http werden die Rohdaten an Sim2CAN
- von dort auf den CAN-Bus gelegt

Embedded PC

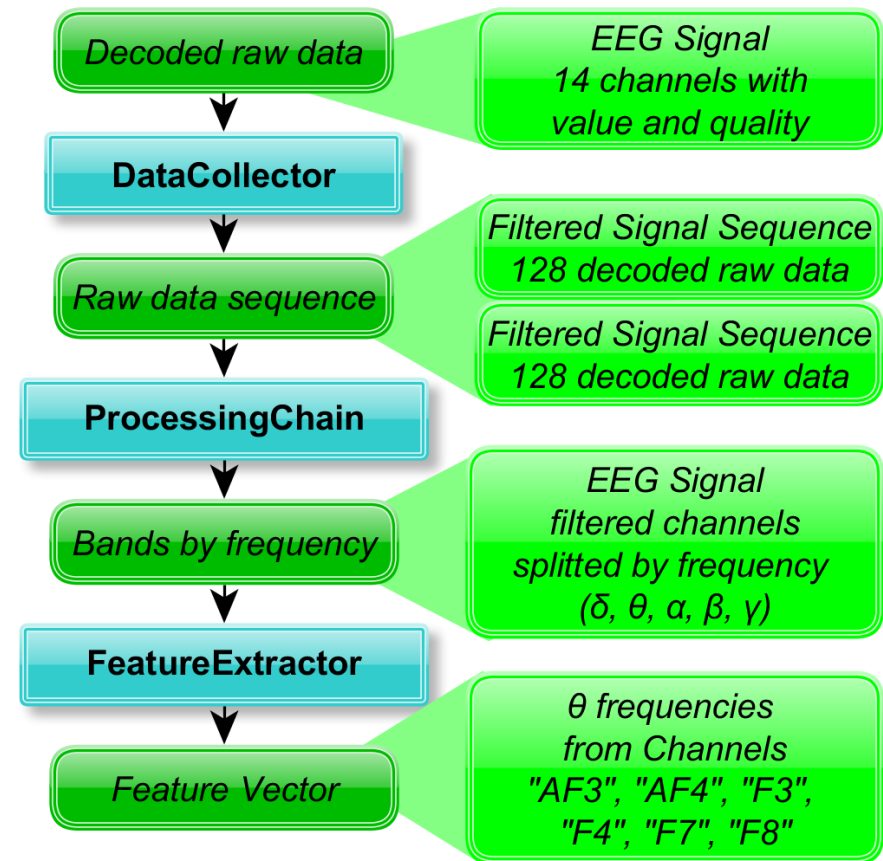
- das CarInterface holt die relevanten Daten vom CAN Bus
- die Datenverarbeitung wird angestoßen
- bei erkannter Müdigkeit bekommt der Fahrer eine entsprechende Meldung

Dies simuliert das EEG als Teil des Fahrzeugs,
sodass es vom virtuellen Steuergerät verwaltet wird.




5 EEG Datenfluss

- Rohdaten bestehen aus
 - 14 EEG Kanälen mit Signal-Wert und -Qualität
 - Gyroskopinformationen (X und Y)
 - Zeitstempel
- Daten werden zu einer Sequenz akkumuliert (128 ~ 1s)
- Sequenz wird verarbeitet
- Merkmalsvektor wird erstellt



5 EEG Rohdaten Verarbeitung

- Bandpass Filterung
0,53 – 50 Hz (Butterworth Filter [27])
- Artefakt Entfernung
Einfache Schwellwertprüfung -100 bis 100
- Normalisierung
Auf Intervall -1 bis 1
- Fast-Fourier-Transformation
Zeitbereich in Frequenzbereich
- Aufteilung in Frequenzbänder
 δ , θ , α , β , γ



5 Merkmalsextraktion

- Gesucht: Unterschiede in den Daten zwischen Anfang und Ende es Experiment
- Es wurden Zusammenhänge zwischen Veränderungen der Alpha- und Theta-Wellen und Veränderungen der kognitiven Fähigkeiten festgestellt [33] .
- Ohne eindeutiges Ergebnis:
Nulldurchgangsrage, Signalenergie, Standardabweichung, Varianz
- Kleinere Unterschiede in der durchschnittlichen Stärke der Theta-Wellen (4 – 8 Hz)
- Am deutlichsten in den Sensoren „AF3“, „AF4“, „F3“, „F4“, „F7“, „F8“
- Merkmalsvektor
 - $4 \text{ (Theta-Wellen)} * 6 \text{ (Sensoren)} = 24$

5 Klassifikator I

Künstliches Neuronales Netz

- Häufig gewählter Klassifikator [14] [15] [18] [19]
- Gut erforscht
- Gute Toolunterstützung (PyBrain)

Funktionsweise

X : Eingabevektoren (Merkmalsmenge)

W : Gewichtsvektor


Σ : Skalarprodukt von X und W

θ : Schwellwert

Wenn $h > \theta$ feuert Perceptron ($o = 1$)


Schaltet man mehrere Perceptrons [34]

hintereinander erhält man ein Multi-Layer-Perceptron



Oben: Einfaches KNN: Perceptron [35]

Unten: Erweitertes KNN: Multi Layer Perceptron [35]



5 Klassifikator II

- Parameter (rechts) werden durch ausprobieren gesucht, es existiert kein Algorithmus, der die „besten“ Parameter bestimmen kann.
- W und θ werden initial zufällig gewählt
- Beim Lernen werden W und θ immer wieder angepasst, bis die Erfolgsrate stimmt.

Inputs = 24
Hidden Layer = 4
Outputs = 1 (binär)

Parameter

- Lernrate: 0,005
- Momentum: 0,25
- Max. Iterations: 5000
- Dauer pro Training ca. 30Min

Ergebnis

| | Wach | Müde | Erkannt |
|--------|-------|------|---------|
| Wach | 357 | 227 | 61% |
| Müde | 217 | 367 | 62% |
| Gesamt | 61,5% | | |

6 Ergebnis

Anwendung zur Akquise, Verarbeitung und Klassifizierung von EEG Daten mit dem Ziel Müdigkeit der Testperson zu erkennen.

Anforderungen

- Präzision und Genauigkeit nicht annähernd erreicht
- Fehlertoleranz und -behandlung sind durch Tests sichergestellt
- Verarbeitung eines Fensters im Testbetrieb ca. 200ms (ein Fenster ~ 1000ms)
- Das System portabel und kann mit Laptop in einem echten Fahrzeug eingesetzt werden
- Das Headset auch komfortabler als ein medizinisches EEG,
die Einrichtung ist jedoch aufwändiger als gedacht
- Ressourcenverbrauch und Eignung auf anderen Gerätetypen wurde nicht getestet
- Die Anwendung ist flexibel und lässt sich in die Fahrsimulatorumgebung einbetten
- Einfache Rückmeldung bei erkannter Müdigkeit
- Die Anwendung (Module, Klassen, Methoden) ist komplett dokumentiert und durch UnitTests abgesichert

7 Fazit

Die Anwendung ist ein vielversprechendes Grundgerüst, aber die Erkennungsrate ist unzureichend

Mögliche Gründe

- Experiment zu kurz (undeutlicher Unterschied zwischen Wach und Müde)
- Fehler in der Rohdatenakquise oder der Verarbeitungskette
- Pech bei der Auswahl der initialen KNN Parameter

Mögliche Lösungen

- Verlängertes Experiment
- Bei EMOTIV nach einer passenden Software zur Datenakquise fragen
- Nach weiteren Bibliotheken zur Verarbeitung suchen
- Weitere Trainingseinheiten mit dem KNN

Zu kurze Zeit (ca. 6 Wochen) für Experiment und Implementierung

7 Ausblick

To-Do

- Die Genauigkeit erhöhen
- Einbettung in den Simulator rund machen
- Geeignete Form der Rückmeldung einsetzen
- Tests in echter Fahrsituation durchführen

Seit September wird das Projekt im Rahmen der Masterthesis weitergeführt

- Ideen aus dem Ergebnis ausprobieren
- Anwendung mit EKG Sensoren erweitern

8 Learnings / Master Projekt

- Fachlich: Funktionsweise EEG, Signalverarbeitung, KNN, Python
- Abwägung Third-Party-Software oder eigene Lösung hierfür Teil 1 des Masterprojekt zum Ausprobieren nutzen
- Umfang klar abstecken - „musts“ und „shoulds“ definieren
- Plan B bei fehlender Hardware
Bestellung möglichst in Teil 1

Master Projekt

- Erstellen einer Latexvorlage für die Ausarbeitung
- Einführung / Dokumentation des [Fahrsimulators](#)
- SVN Repos nach git migriert und Workflow vorbereitet
- Kommunikation EEG Headset Reparatur (Februar - Juli)

Vielen Dank!
Noch Fragen?



9 Quellen

[2] X. Mosquet, M. Andersen, and A. Arora. A roadmap to safer driving through advanced driver assistance systems. <https://www.bcgperspectives.com/Images/MEMA-BCG-A-Roadmap-to-Safer-Driving-Sep-2015.pdf>, 2015. Zugriff: 2015-10-28.

[4] Stat. Bundesamt. Zahl der verkehrstoten steigt im jahr 2015 vorrausichtlich auf etwas 3450. https://www.destatis.de/DE/PresseService/Presse/Pressemitteilungen/2015/12/PD15_463_46241.html, 2015. Zugriff: 2015-12-31.

[5] C. Evers. Unterschätzte Risikofaktoren Übermüdung und ablenkung als ursachen für schwere lkw-unfälle. http://www.dvr.de/presse/seminare/904_20.htm, 2008. Zugriff: 2015-10-20.

[10] L. Zhang, F. Liu, and J. Tang. Real-time system for driver fatigue detection by rgb-d camera. *ACM Trans. Intell. Syst. Technol.*, 6(2):22:1–22:17, March 2015.

[11] L. M. Bergasa, J. Nuevo, M. A. Sotelo, R. Barea, and M.E. Lopez. Real-time system for monitoring driver vigilance. *Intelligent Transportation Systems, IEEE Transactions on*, 7(1):63–77, March 2006.

[12] J. Vicente, P. Laguna, A. Bartra, and R. Bailon. Detection of driver's drowsiness by means of hrv analysis. In *Computing in Cardiology, 2011*, pages 89–92, Sept 2011.

[13] E. Rogado, J.L. Garcia, R. Barea, L. M. Bergasa, and E. Lopez. Driver fatigue detection system. In *Robotics and Biomimetics, 2008. ROBIO 2008. IEEE International Conference on*, pages 1105–1110, Feb 2009.

[14] R. N. Khushaba, S. Kodagoda, S. Lal, and G. Dissanayake. Driver drowsiness classification using fuzzy wavelet-packet-based feature-extraction algorithm. *Biomedical Engineering, IEEE Transactions on*, 58(1):121–131, Jan 2011.

[15] R. R. Johnson, D. P. Popovic, R. E. Olmstead, M. Stikic, D. J. Levendowski, and C. Berka. Drowsiness/alertness algorithm development and validation using synchronized EEG and cognitive performance to individualize a generalized model. *Biological psychology*, 87(2):241–250, May 2011.

[16] A. Subasi. Automatic recognition of alertness level from eeg by using neural network and wavelet coefficients. *Expert Syst. Appl.*, 28(4):701–711, May 2005.

[17] A. Vuckovic, V. Radivojevic, A. C.N. Chen, and D. Popovic. Automatic recognition of alertness and drowsiness from {EEG} by an artificial neural network. *Medical Engineering & Physics*, 24(5):349 – 360, 2002.

[18] R. S. Huang, K. J. Chung, L.-L. Tsai, and O. T. C. Chen. Eeg pattern recognition-arousal states detection and classification. In *Neural Networks, 1996., IEEE International Conference on*, volume 2, pages 641–646 vol.2

[19] C.-T. Lin, R.-C. Wu, S.-F. Liang, W.-H. Chao, Y.-J. Chen, and T.-P. Jung. Eeg-based drowsiness estimation for safety driving using independent component analysis. *IEEE Trans. Circuits Syst. I, Reg. Papers*, pages 2726–2738, 2005.

[23] A. Zhang and F. Liu. Drowsiness detection based on wavelet analysis of ecg and pulse signals. In *Biomedical Engineering and Informatics (BMEI), 2012 5th International Conference on*, pages 491–495, Oct 2012.

[24] J. Engstrom, E. Johansson, and J. Ostlund. Effects of visual and cognitive load in real and simulated motorway driving. *Transportation Research Part F: Traffic Psychology and Behaviour*, 8(2):97–120, March 2005.

[27] S. Butterworth. On the theory of filter amplifiers. *Wireless Engineer*, 7, 1930.

[33] N. R. Pal, C.-Y. Chuang, L.-W. Ko, C.-F. Chao, T.-P. Jung, S.F. Liang, and C.-T. Lin. Eeg-based subject- and session-independent drowsiness detection: An unsupervised approach. *EURASIP J. Adv. Signal Process*, 2008:192:1–192:11, January 2008.

[34] W. S. McCulloch and W. Pitts. A logical calculus of the ideas immanent in nervous activity. *The bulletin of mathematical biophysics*, 5(4):115–133, 1943.

[35] S. Marsland. *Machine learning : an algorithmic perspective*. Chapman & Hall/CRC machine learning & pattern recognition series. CRC Press, Boca Raton, 2009. A Chapman & Hall book.